심화 알고리즘

-M5 Forecasting-

현예성 김민석 최성웅 문구영 이노아 강호석



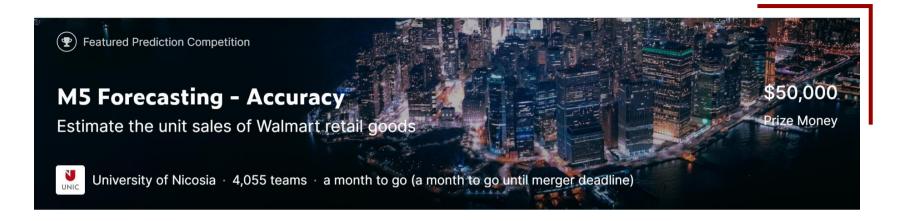
INDEX

1. EDA

2. Light GBM

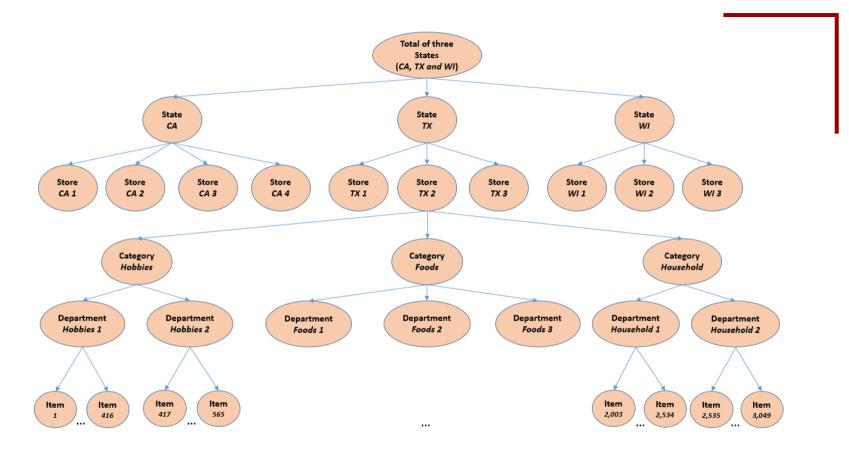
3. LSTM





Files

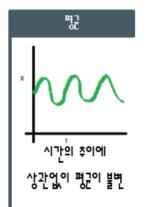
- calendar.csv Contains information about the dates on which the products are sold.
- sales_train_validation.csv Contains the historical daily unit sales data per product and store [d_1 d_1913]
- sample_submission.csv The correct format for submissions. Reference the Evaluation tab for more info.
- sell_prices.csv Contains information about the price of the products sold per store and date.
- sales_train_evaluation.csv Available once month before competition deadline. Will include sales [d_1 d_1941]

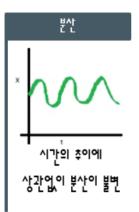


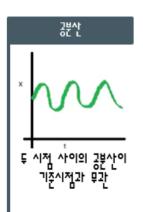


Time Series

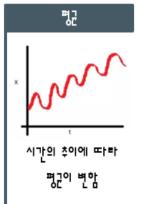
Stationary Series

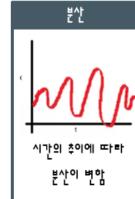


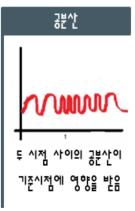




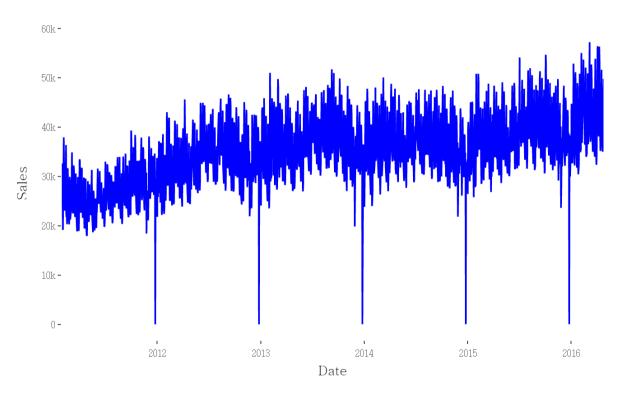
Non-Stationary Series





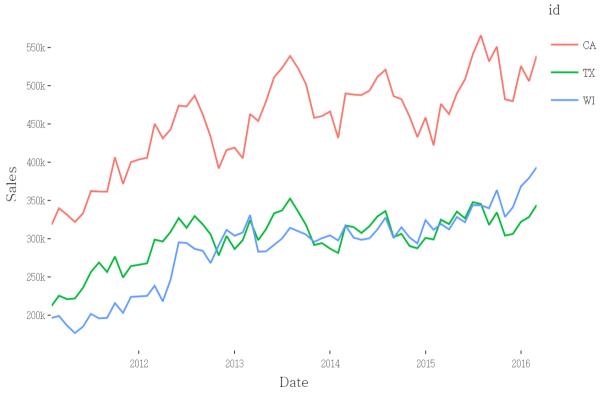


total aggregate sales



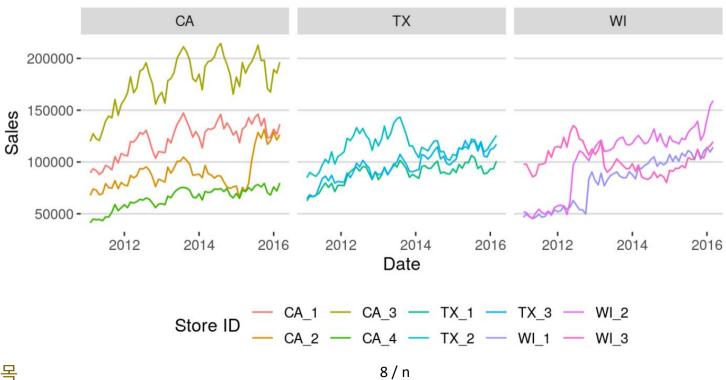


Monthly sales per State



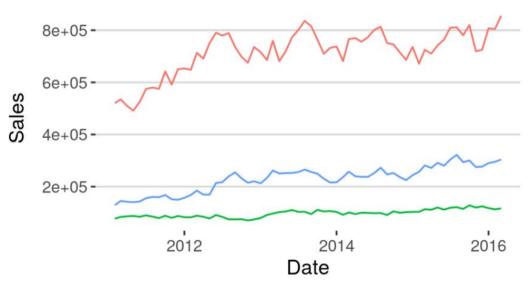


Sales per Store

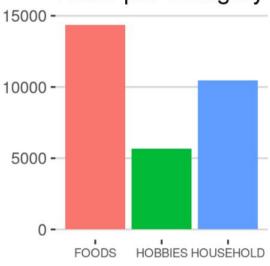




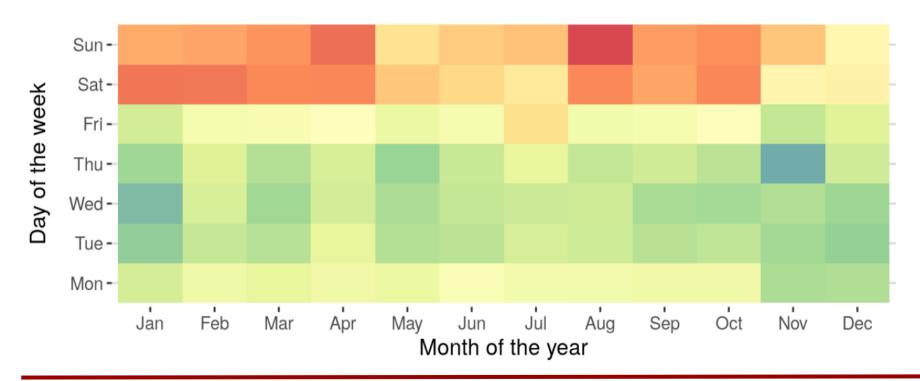


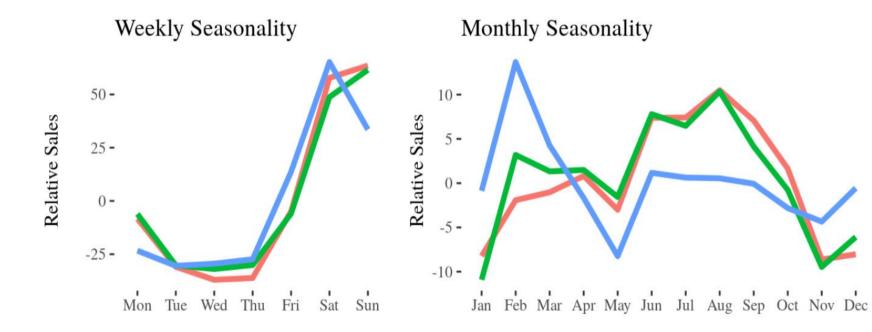


Rows per Category





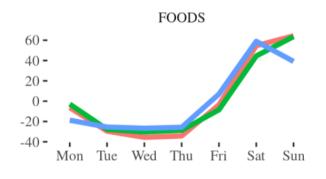


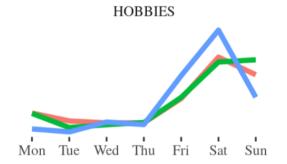


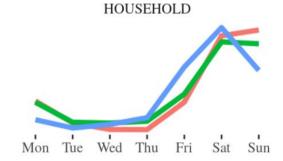


Weekly Seasonality



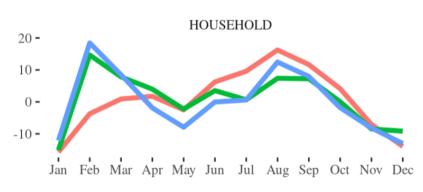




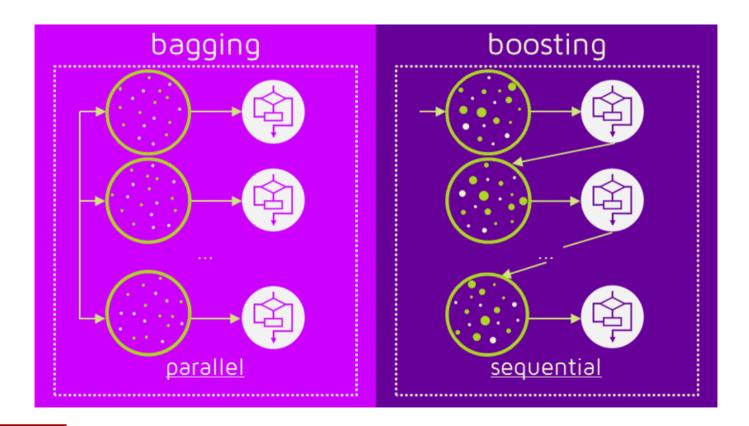


Monthly Seasonality by Category & State





Boosting





Boosting

Overfitting 문제 개선 - Bagging 단일 모델의 성능 개선 - Boosting / bias 감소에 초점 - 모수 조정이 중요 / outlier에 취약

Ada Boost

데이터셋에서 샘플을 추출하여 여러 분류기에 적용해서 학습시킨다. 시행 결과 잘못 분류된 데이터를 집중적으로 학습하여 다음 fitting에 활용. Noise나 Outlier가 심한 데이터의 경우, 문제가 발생할 수 있다.

Gradient Boost

Gradient Descent를 Ada Boost에 적용한 기법. Outlier, Noise 문제를 해결할 수 있으나, 연산량이 많아짐

XG Boost

Gradient Boost의 많은 연산량을 CPU 분산처리기법 등을 통해 소화하는 방식.

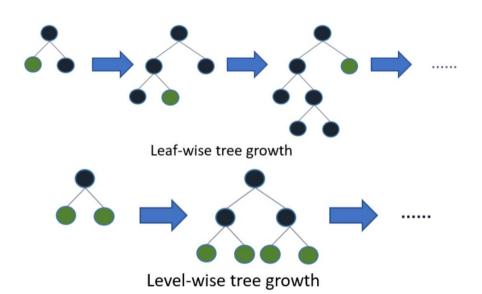


Light GBM

- 학습 속도가 느린 XGBoost의 단점을 보안 GOSS(Gradient-based One-Sided Sampling) / EFB(Exclusive Feature Bundling) 사용
- 대용량 데이터 처리가 가능
- 타 모델에 비해 적은 메모리 사용
- 정보의 손실을 줄일 수 있음

리프 중심 트리 분할

: 최대 손실 값을 가지는 리프 노드 지속적 분할



균형 트리 분할



모델 적합

	id item_id	dept_id	store_id	cat_id	state_id	d	sales	date	wm_yr_wk	 month	year	event_name_1	event_type_1	event_name_2	event_type_2	snap_CA	snap_TX	snap_WI	sell_price
0 HOBBIES_1_002_CA_1_validation	on 1	0	0	0	0	d_250	0.0	2011- 10-05	11136	 10	2011	0	0	0	0	1.0	1.0	1.0	3.97
1 HOBBIES_1_002_CA_1_validation	on 1	0	0	0	0	d_251	0.0	2011- 10-06	11136	 10	2011	0	0	0	0	1.0	1.0	1.0	3.97
2 HOBBIES_1_002_CA_1_validation	on 1	0		0	0	d_252	0.0	2011- 10-07	11136	 10	2011	0		0	0	1.0	1.0	0.0	3.97
3 HOBBIES_1_004_CA_1_validation	on 3	0	0	0									0	0	0	1.0	1.0	1.0	4.34
4 HOBBIES_1_004_CA_1_validation	on 3	0	0	0	0	d_251	4.0	2011- 10-06	11136	 10	2011	0	0	0	0	1.0	1.0	1.0	4.34

5 rows × 22 columns



모델 적합

변수 추가

lag_7	lag_28	rmean_7_7	rmean_28_7	rmean_7_28	rmean_28_28	week	quarter	mday
0.0	0.0	0.000000	0.142857	0.178571	0.285714	48	4	29
0.0	0.0	0.000000	0.000000	0.142857	0.285714	48	4	30
0.0	1.0	0.000000	0.142857	0.142857	0.321429	48	4	1
0.0	0.0	0.000000	0.142857	0.142857	0.321429	48	4	2
1.0	1.0	1.428571	1.428571	1.607143	1.785714	48	4	29

모델 적합

```
params = {
          "objective" : "poisson", #poisson regression
          "metric" :"rmse".
          "force row wise" : True, #learning direction (relatively small columns)
          "learning rate" : 0.075,
          "sub row" : 0.75,
          "bagging_freq" : 1, #0 means disable bagging; k means perform bagging at every k iteration
          "lambda 12" : 0.1, #L2 regularization
          "metric": ["rmse"],
          'verbosity': 1, # Info
          'num_iterations' : 1200,
          'num_leaves': 128,
          "min data in leaf": 100,
```



결과

	id	F1	F2	F3	F4	F5	F6	F7	F8	F9	 F19	F20	F21	F22
0	FOODS_1_001_CA_1_validation	0.900208	0.850305	0.835608	0.808511	1.068399	1.240130	1.336629	1.036806	1.005700	 1.092689	1.365811	1.295096	1.031251
1	FOODS_1_001_CA_2_validation	0.826054	0.846310	0.782934	1.054960	1.074849	1.252265	1.328782	0.880883	0.909217	 1.181405	1.557242	1.386192	0.970276
2	FOODS_1_001_CA_3_validation	1.224390	1.119274	0.986613	0.970576	1.063056	1.244171	1.236825	1.119709	1.136489	 1.119759	1.659144	1.779672	1.205213
3	FOODS_1_001_CA_4_validation	0.401395	0.349750	0.346810	0.351312	0.421821	0.429025	0.513803	0.390084	0.421533	 0.446922	0.482879	0.506504	0.376197
4	FOODS_1_001_TX_1_validation	0.220046	0.218440	0.224843	0.227519	0.220456	0.218982	0.261482	0.561683	0.514396	 0.410909	0.429856	0.445446	0.311021
		•••			•••				•••		 •••		•••	
60975	HOUSEHOLD_2_516_TX_2_evaluation	0.283826	0.260213	0.288633	0.284374	0.353788	0.432488	0.343618	0.238760	0.241598	 0.292015	0.364561	0.354640	0.247517
60976	HOUSEHOLD_2_516_TX_3_evaluation	0.167784	0.155329	0.171575	0.161759	0.198939	0.226477	0.171531	0.124789	0.121023	 0.161521	0.179582	0.165588	0.139283
60977	HOUSEHOLD_2_516_WI_1_evaluation	0.091761	0.084142	0.083611	0.091436	0.103181	0.113265	0.104594	0.096435	0.092222	 0.129596	0.143583	0.136628	0.099333
60978	HOUSEHOLD_2_516_WI_2_evaluation	0.042751	0.040404	0.040279	0.087703	0.106358	0.104421	0.097441	0.090797	0.090362	 0.133645	0.132977	0.121293	0.105357
60979	HOUSEHOLD_2_516_WI_3_evaluation	0.054448	0.052615	0.052839	0.057376	0.074295	0.062670	0.062580	0.100624	0.098897	 0.144387	0.149870	0.138397	0.115388



0.43918

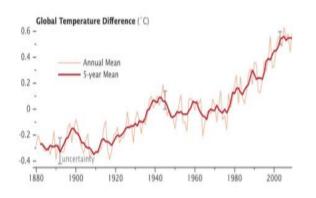


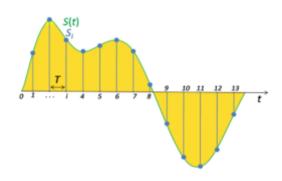
0.49670



순차 데이터 (Sequential Data)

순서가 의미를 가지며, 순서가 달라질 경우 의미가 손상되는 데이터







세계 기온 변화 (Temporal Sequence)

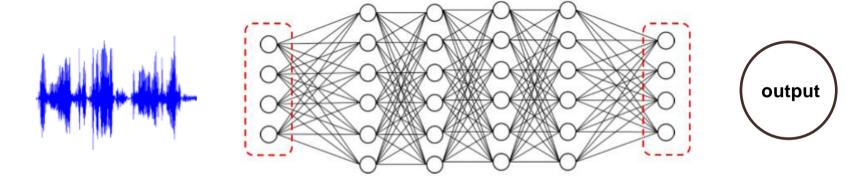
샘플링된 소리 신호 (Time series)

주식 가격 시계열 데이터 (Time series)

시간적 의미가 있는 경우 Temporal Sequence, 일정한 시간차라면 Time Series



심층 신경망과 순차 데이터



Fixed-Length Vector?

입력되는 시계열의 길이는 매번 다름

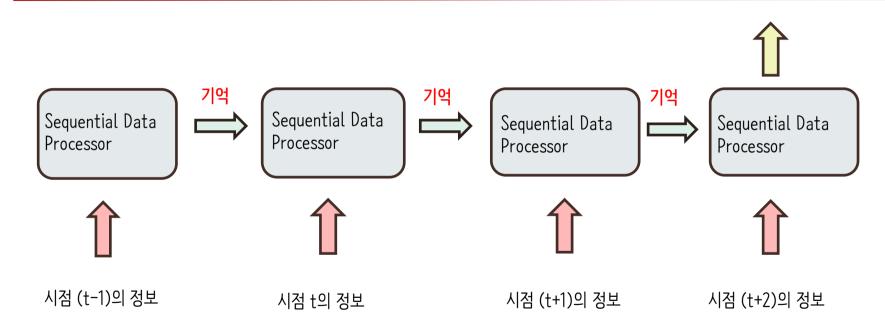
데이러는 시간 순서에 의존적

One-Hot vector

무수히 많은 클래스가 필요

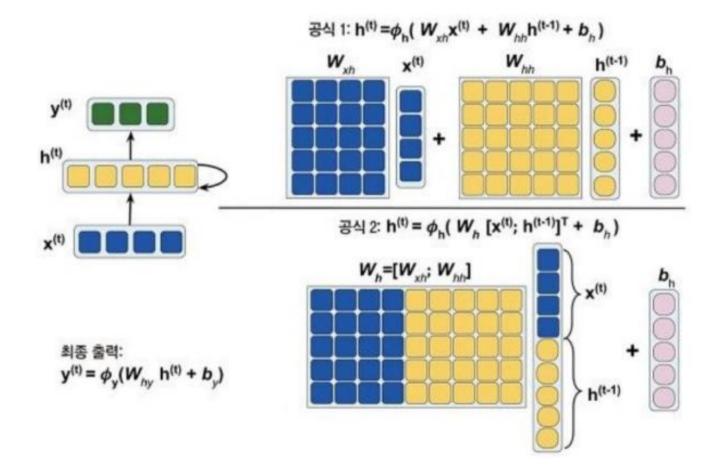


기억 시스템(Memory System)



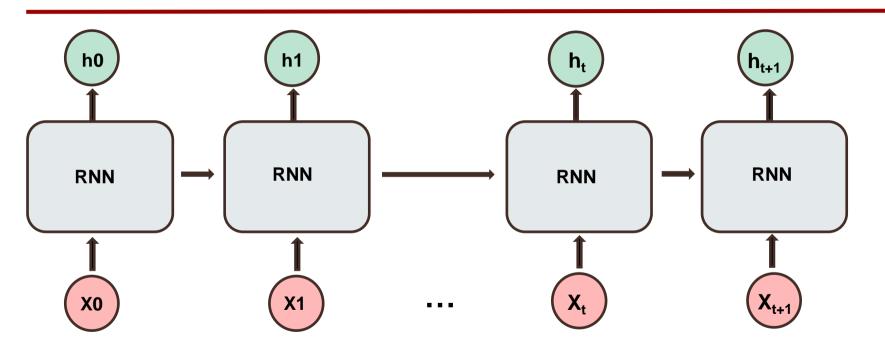
올바른 출력을 내려면, 입력을 받을 때 마다 그 내용을 '기억'할 수 있어야 한다.





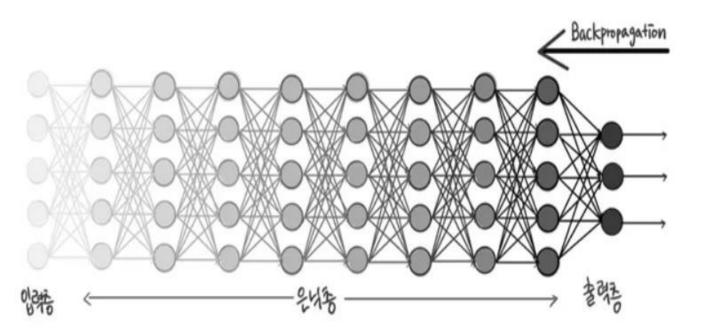


순환 신경망 (RNN)의 한계



어떤 입력의 정보가 사용되는 시점의 차이가 많이 날 경우, 학습능력이 저하된다.





장기 기억에 있어 취약

오래된 시점의 노드가 담고 있는 정보, 신호가 제대로 전파되지 않음 (정보 손실)



Back Propagation Through Time

$$\frac{\partial L^{(t)}}{\partial W_{hh}} = \frac{\partial L^{(t)}}{\partial y^{(t)}} \times \frac{\partial y^{(t)}}{\partial h^{(t)}} \times \left(\sum_{k=1}^{t} \frac{\partial h^{(t)}}{\partial h^{(k)}} \times \frac{\partial h^{(k)}}{\partial w_{hh}} \right) \qquad \bullet \frac{\partial h^{(t)}}{\partial h^{(k)}} = \prod_{i=k+1}^{t} \frac{\partial h^{(i)}}{\partial h^{(i-1)}}$$

•
$$\frac{\partial \mathbf{h}^{(t)}}{\partial \mathbf{h}^{(k)}} = \prod_{i=k+1}^{t} \frac{\partial \mathbf{h}^{(i)}}{\partial \mathbf{h}^{(i-1)}}$$

전체 손실 I 은 t=T까지 각 타임 스텝의 모든 손실 함수의 합

타임 스텝 t에서의 손실은 모든 이전 타임 스텝 1~(t-1)의 은닉층에 의존

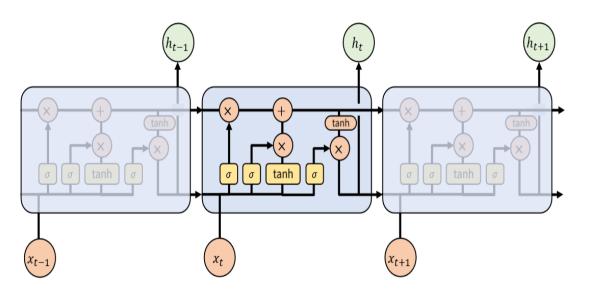
기울기 소실 / 폭주 문제

(t-k)개의 곱셈: 가중치 w가 (t-k)번 곱해져 w (t-k)가 된다

|w| >1: 폭주 / |w| <1: 소실



Long Short-Term Memory



다음 층으로 기억된 값을 넘길 지, 넘기지 않을 지를 관리

과거의 신호를 전파

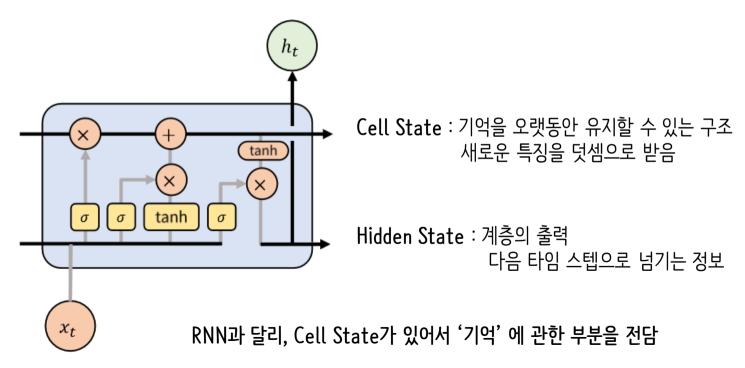
기울기 소실 문제를 극복

기억할 것은 오래 기억하고, 잊을 것은 빨리 잊어버리는 능력

삭제, 입력, 출력 게이트로 구성

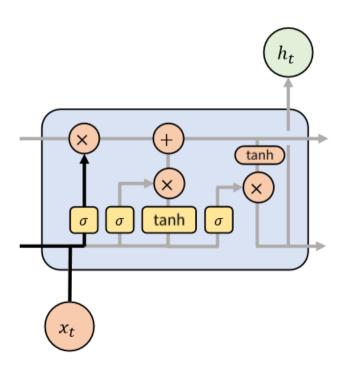


Cell, Hidden State





Forget Gate

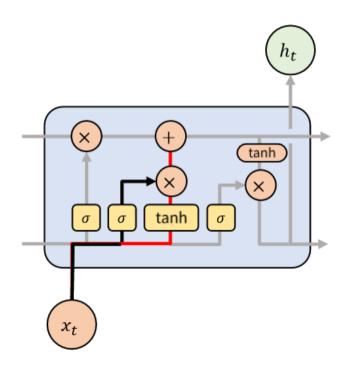


Forget Gate

- Sigmoid 활성 함수, 0~1의 값
- Cell State에 그 값을 곱해주어서 <mark>얼만큼 잊을지</mark> 결정
- 메모리 셀이 무한정 성장하지 않도록 셀 상태 설정
- 통과할 정보, 억제할 정보를 결정



Input Gate



Input Gate

- Sigmoid 활성 함수, 0~1의 출력값
- 새롭게 추출한 특징을 얼만큼 사용할 지 결정
- 셀 상태를 업데이트



$$f_t = \partial (w_{xf} x^{(t)} + w_{hf} h^{(t-1)} + b_f)$$
: 셀 상태를 다시 설정

$$i_t = \partial (w_{xi} x^{(t)} + w_{hi} h^{(t-1)} + b_i)$$

g_t: 입력 노드

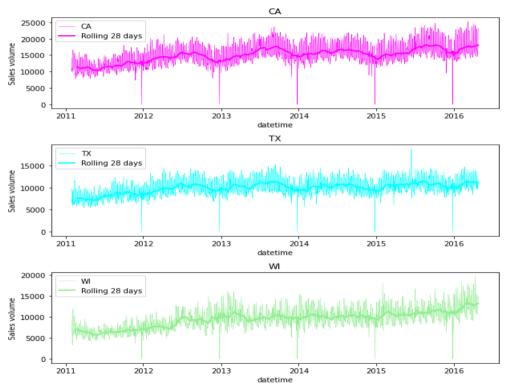
$$C^{(t)} = (C^{(t-1)} \odot f_t) + (i_t \odot g_t)$$
 : t에서의 셀 상태

$$O_t = \partial (w_{xo} x^{(t)} + w_{ho} h^{(t-1)} + b_o)$$
: 은닉 유닛의 출력 업데이트

$$h_t = O_t \odot tanh(C^{(t)})$$
: 현재 타임스텝의 은닉 유닛의 출력



Moving Average for Stationary

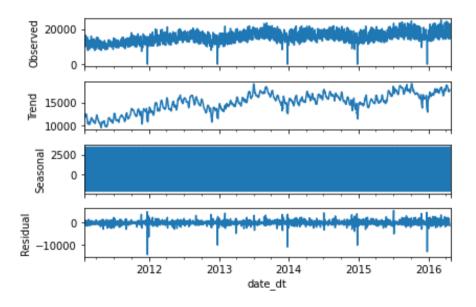


state_group[state_col[i]].rolling(28).mean() >> 28일 간격의 이동평균



from statsmodels.tsa.seasonal import seasonal_decompose result_CA = seasonal_decompose(state_group['CA']) fig = plt.figure(figsize= (20,15)) fig = result_CA.plot()

<Figure size 1440x1080 with 0 Axes>



$$y_t = S_t + T_t + R_t$$

 y_t : data

S_t: 계절성분

T_t : 추세-주기 성분

R_t: 나메지 성분 (Residual)



Data

store_group_minmax_scaled.head()

	date	CA_1	CA_2	CA_3	CA_4	TX_1	TX_2	TX_3	WI_1	WI_2	 month	year	d	event_name_1	event_type_1	evenț
0	2011- 01- 29	0.478530	0.434718	0.295064	0.326010	0.297974	0.558541	0.277108	0.391594	0.219526	 1	2011	d_1	NaN	NaN	
1	2011- 01- 30	0.442181	0.351632	0.308553	0.385641	0.332889	0.571300	0.272445	0.317681	0.172943	 1	2011	d_2	NaN	NaN	
2	2011- 01- 31	<u>0.174755</u>	0.180082	0.148835	0.232248	<u>0.102345</u>	0.390273	0.120676	0.226087	0.186332	 1	2011	d_3	NaN	NaN	
3	2011- 02- 01	0.221690	0.217730	0.217351	0.253433	0.218550	0.423747	0.109794	<u>0.181014</u>	0.256625	 2	2011	d_4	NaN	NaN	
4	2011- 02- 02	0.137607	0.146884	0.153740	0.291095	0.068230	0.354398	0.023708	0.000000	0.068759	 2	2011	d_5	NaN	NaN	



```
target_store = distinct_store_names[x]

# scaled data 설정
data_scaled = store_group_minmax_scaled[target_store].ravel().reshape(-1,1)

# train, test split
train_data, test_data = data_scaled[:len(data_scaled) - 56], data_scaled[len(data_scaled) - 56 : ]
```

시계열 Generator

n_input = 28 n features= 1

train_generator = TimeseriesGenerator(train_data, train_data, length=n_input, batch_size=1)
test_generator = TimeseriesGenerator(test_data, test_data, length=n_input, batch_size=1)

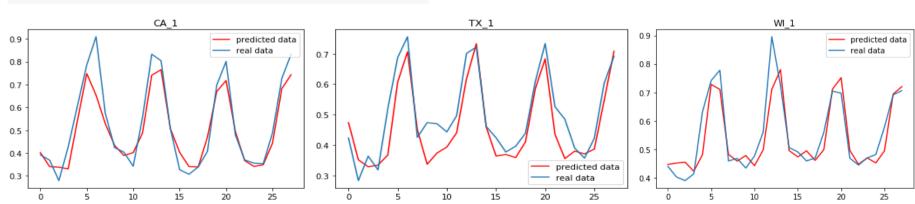
(y_{t-1}, y_{t-2}, ···, y_{t-28}) : 특성변수 >>> 은닉층 >>> y_t : 목적변수

28개의 과거 시점 매출액으로 현 시점의 매출액을 예측



```
model = Sequential()
model.add(LSTM(4, activation = 'tanh', input_shape=(n_input, 1)))
model.add(Dense(1))
model.compile(loss='mean_squared_error', optimizer='adam')
model.summary()

history = model.fit_generator(train_generator, epochs=32).history
yhat = model.predict(test_generator)
print(y_hat)
```





최종 발표 전 계획

- 1. 시계열 분해를 통한 예측
- 2. Stacking Model
- 3. 변수 및 hyper-parameter 조점



